

Laporan Analisis

Mini Search Engine

Temu Kembali Informasi | Projek UTS

Topik Dataset: Opini Masyarakat tentang Imunisasi & Vaksinasi Balita

Jumlah Dokumen (N): 50

TF-IDF | Vector Space Model | Cosine Similarity | Sastrawi Stemmer

A. Analisis Bobot (IDF)

Dua Kata Kunci yang Dipilih

Dari topik kelompok kami mengenai Imunisasi Balita, kami memilih dua kata kunci berikut:

No	Kata Kunci	Kata Setelah Stemming	df
1	Campak	campak	13
2	Vaksin	vaksin	22

Perhitungan IDF - Langkah demi Langkah

Rumus IDF yang digunakan:

$$IDF(t) = \log_{10}(N / df(t))$$

di mana:

N = total dokumen dalam koleksi = 50

$df(t)$ = jumlah dokumen yang mengandung term t

Kata Kunci 1: "Campak" (df = 13)

Langkah 1: Tentukan nilai N dan df

$$N = 50, \quad df(campak) = 13$$

Langkah 2: Hitung rasio N/df

$$N / df(campak) = 50 / 13 = 3,8462$$

Langkah 3: Hitung logaritma basis 10

$$IDF(campak) = \log_{10}(3,8462) = 0,5850$$

Kata Kunci 2: "Vaksin" (df = 22)

Langkah 1: Tentukan nilai N dan df

$$N = 50, \quad df(vaksin) = 22$$

Langkah 2: Hitung rasio N/df

$$N / df(vaksin) = 50 / 22 = 2,2727$$

Langkah 3: Hitung logaritma basis 10

$$IDF(vaksin) = \log_{10}(2,2727) = 0,3565$$

Perbandingan Hasil

Term	df	N/df	IDF
campak	13	3,8462	0,5850

vaksin	22	2,2727	0,3565
--------	----	--------	--------

Mengapa Kata yang Lebih Jarang Muncul Memiliki Bobot Lebih Tinggi?

Kata "campak" memiliki IDF lebih tinggi (0,5850) dibanding "vaksin" (0,3565) karena:

1. Prinsip Diskriminasi: Kata yang muncul di sedikit dokumen (df rendah) memiliki kemampuan membedakan (diskriminatif) yang lebih baik. Kata "campak" hanya muncul di 13 dari 50 dokumen, sehingga jika sebuah dokumen mengandung kata "campak", dokumen tersebut lebih spesifik membahas topik campak.
2. Kebalikan Frekuensi Dokumen: IDF adalah Inverse Document Frequency - semakin jarang sebuah kata muncul di banyak dokumen, semakin tinggi bobotnya. Ini karena kata yang muncul di hampir semua dokumen tidak memberikan informasi berguna untuk membedakan dokumen satu dengan lainnya.
3. Contoh Konkret: Kata "vaksin" muncul di 22 dokumen (44% koleksi) karena hampir semua opini dalam dataset membahas vaksin secara umum. Sebaliknya, "campak" hanya di 13 dokumen (26%) karena lebih spesifik merujuk pada penyakit tertentu. Jadi saat pengguna mencari "campak", kata ini lebih berguna untuk menemukan dokumen yang benar-benar relevan.
4. Formula Matematis: Rasio N/df menghasilkan angka lebih besar ketika df kecil. Logaritma kemudian menskala angka ini agar tidak terlalu ekstrem, tapi tetap mempertahankan perbedaan bobot.

B. Analisis Efek Normalisasi

Perbandingan Hasil: Dot Product vs Cosine Similarity

Kami menjalankan kueri "imunisasi campak" dengan dua metode:

- Tanpa normalisasi: Dot Product (perkalian titik vektor query x dokumen)
- Dengan normalisasi: Cosine Similarity (dot product dibagi panjang kedua vektor)

Rumus Cosine Similarity:

$$\text{CosSim}(q, d) = (q \cdot d) / (|q| \times |d|)$$

Rank	Dok(Dot)	Skor Dot	Pjg Dok	Dok(Cos)	Skor Cos	Pjg Dok
1	#27	0,5931	135	#38	0,1557	22
2	#14	0,5681	40	#14	0,1420	40
3	#36	0,5207	97	#21	0,1177	29
4	#38	0,5172	22	#9	0,1101	36
5	#9	0,4569	36	#34	0,1076	29
6	#21	0,4569	29	#42	0,1047	20
7	#34	0,4569	29	#48	0,0923	30
8	#26	0,3574	91	#40	0,0922	23
9	#4	0,3539	22	#4	0,0915	22
10	#40	0,3539	23	#19	0,0808	24

Analisis Perbedaan Ranking

Dokumen Panjang Mendominasi Tanpa Normalisasi

Tanpa normalisasi (Dot Product):

- Dokumen #27 (135 token) menempati peringkat 1 dengan skor 0,5931
- Dokumen #36 (97 token) menempati peringkat 3 dengan skor 0,5207
- Dokumen #26 (91 token) menempati peringkat 8 dengan skor 0,3574

Ketiga dokumen ini adalah dokumen terpanjang dalam koleksi. Namun dengan normalisasi (Cosine Similarity), ketiganya TIDAK masuk top-10 sama sekali.

Sebaliknya, Dokumen #38 (22 token) yang pendek justru naik dari peringkat 4 (Dot Product) ke peringkat 1 (Cosine Similarity).

Mengapa Dokumen Panjang Cenderung Skor Lebih Tinggi Tanpa Normalisasi?

1. Akumulasi Term Frequency: Dokumen yang lebih panjang secara alami mengandung lebih banyak term dan frekuensi kemunculan term lebih tinggi. Ketika kita menghitung dot product, setiap kemunculan term berkontribusi pada skor total. Dokumen panjang memiliki lebih banyak "peluang" untuk mengandung term query, sehingga dot

product-nya lebih besar.

2. Panjang Vektor Lebih Besar: Dalam Vector Space Model, setiap dokumen direpresentasikan sebagai vektor dalam ruang berdimensi-V. Dokumen panjang menghasilkan vektor dengan magnitude (panjang) lebih besar karena lebih banyak dimensi yang memiliki nilai non-zero.
3. Cosine Menghilangkan Bias Panjang: Cosine Similarity menormalisasi dot product dengan membaginya dengan panjang (magnitude) kedua vektor. Normalisasi ini memastikan bahwa yang diukur adalah sudut antara dua vektor, bukan panjangnya.
4. Contoh Konkret: Dokumen #27 (135 token) membahas banyak aspek sehingga konsentrasi topik rendah. Dokumen #38 (22 token) sangat fokus membahas campak dan imunisasi. Meski pendek, proporsi term relevan terhadap total term sangat tinggi.
5. Hubungan dengan VSM: Dalam Vector Space Model, dokumen dan kueri direpresentasikan sebagai vektor. Cosine Similarity mengukur kesamaan arah vektor, bukan besarnya. Ini sesuai dengan intuisi bahwa relevansi seharusnya diukur dari seberapa mirip distribusi topik dokumen dengan query, bukan seberapa banyak kata yang dikandungnya.

C. Evaluasi Sistem

Kami menguji sistem dengan 2 kueri dan menentukan Ground Truth berdasarkan penilaian manual terhadap konten dokumen.

Kueri 1: "imunisasi campak"

Tujuan: Mencari dokumen yang membahas tentang imunisasi/vaksinasi campak (measles).

Ground Truth (Dokumen yang Benar-benar Relevan)

No	Doc ID	Alasan Relevan
1	#4	Baru selesai imunisasi campak kemarin
2	#9	Pasien anak campak, riwayat imunisasi tidak pernah
3	#14	Yg belum imunisasi campak, TOLONG disegerakan
4	#19	KLB campak, pendapat tentang imunisasi/vaksin
5	#21	Meninggal karena campak, blm dapat imunisasi
6	#27	Kasus Campak di Indonesia, imunisasi anaknya
7	#34	Infeksi campak di Sumenep, rendahnya imunisasi
8	#36	Korban jiwa akibat campak, program imunisasi
9	#38	Campak menular, pemberian vaksin, imunisasi
10	#40	Faktor Risiko Campak: Belum/tidak imunisasi
11	#42	Campak bukan sepele, evaluasi cakupan imunisasi

Ground Truth = {4, 9, 14, 19, 21, 27, 34, 36, 38, 40, 42} -> 11 dokumen relevan

Hasil Retrieval Sistem (Top-10)

Rank	Doc ID	Cosine Similarity	Relevan?
1	#38	0,1557	TP
2	#14	0,1420	TP
3	#21	0,1177	TP
4	#9	0,1101	TP
5	#34	0,1076	TP
6	#42	0,1047	TP
7	#48	0,0923	FP
8	#40	0,0922	TP
9	#4	0,0915	TP
10	#19	0,0808	TP

Perhitungan Metrik Evaluasi

- TP (True Positive) = 9 -> dokumen relevan yang berhasil ditemukan
- FP (False Positive) = 1 -> dokumen tidak relevan yang masuk top-10 (Doc #48)
- FN (False Negative) = 2 -> dokumen relevan yang tidak masuk top-10 (Doc #27, #36)

$$\text{Precision} = TP / (TP + FP) = 9 / (9 + 1) = 9/10 = 0,9000$$

$$\text{Recall} = TP / (TP + FN) = 9 / (9 + 2) = 9/11 = 0,8182$$

$$\text{F1-Measure} = 2 \times P \times R / (P + R) = 2 \times 0,9 \times 0,8182 / 1,7182 = 0,8571$$

Kueri 2: "vaksin balita"

Tujuan: Mencari dokumen yang membahas tentang vaksinasi untuk balita.

Ground Truth (Dokumen yang Benar-benar Relevan)

No	Doc ID	Alasan Relevan
1	#5	Imunisasi kejar MR, balita yg belum lengkap
2	#23	Balita yg habis imunisasi demam itu wajar
3	#26	Imunisasi lengkap, vaksin, balita
4	#29	Vaksin imunisasi balita itu gak baik (opini)
5	#32	Bayi-balita dikasi vaksin lengkap, imunisasi
6	#35	Imunisasi program untuk balita
7	#37	Anak bayi balita jgn diimunisasi (opini)
8	#39	Balita abis di imunisasi jadi lagi aktif

Ground Truth = {5, 23, 26, 29, 32, 35, 37, 39} -> 8 dokumen relevan

Hasil Retrieval Sistem (Top-10)

Rank	Doc ID	Cosine Similarity	Relevan?
1	#38	0,0929	FP
2	#29	0,0761	TP
3	#7	0,0687	FP
4	#43	0,0673	FP
5	#20	0,0629	FP
6	#35	0,0588	TP
7	#45	0,0532	FP
8	#39	0,0525	TP
9	#37	0,0506	TP
10	#23	0,0504	TP

Perhitungan Metrik Evaluasi

- TP (True Positive) = 5 -> dokumen relevan yang berhasil ditemukan
- FP (False Positive) = 5 -> dokumen tidak relevan yang masuk top-10
- FN (False Negative) = 3 -> dokumen relevan yang tidak masuk top-10 (Doc #5, #26, #32)

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}) = 5 / (5 + 5) = 5/10 = 0,5000$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN}) = 5 / (5 + 3) = 5/8 = 0,6250$$

$$\text{F1-Measure} = 2 \times P \times R / (P + R) = 2 \times 0,5 \times 0,625 / 1,125 = 0,5556$$

Ringkasan Evaluasi

Metrik	Kueri 1 (imunisasi campak)	Kueri 2 (vaksin balita)
Precision	0,9000 (90%)	0,5000 (50%)
Recall	0,8182 (81,8%)	0,6250 (62,5%)
F1-Measure	0,8571 (85,7%)	0,5556 (55,6%)

Interpretasi Hasil

Kueri 1 - "imunisasi campak" (F1 = 0,857)

Sistem menunjukkan performa sangat baik untuk kueri ini:

Precision 90% berarti dari 10 dokumen yang ditampilkan, 9 di antaranya memang relevan. Hanya 1 dokumen tidak relevan (Doc #48) yang masuk hasil.

Recall 81,8% berarti sistem berhasil menemukan 9 dari 11 dokumen relevan. Dua dokumen yang terlewat (#27 dan #36) adalah dokumen panjang yang skornya turun setelah cosine normalization.

F1 85,7% menunjukkan keseimbangan yang baik antara precision dan recall.

Kinerja tinggi ini karena kata "campak" memiliki IDF tinggi (0,5850) sehingga sangat diskriminatif.

Kueri 2 - "vaksin balita" (F1 = 0,556)

Sistem menunjukkan performa sedang untuk kueri ini:

Precision 50% berarti hanya separuh dari top-10 yang benar-benar relevan. Banyak dokumen yang membahas "vaksin" secara umum (tanpa konteks balita) masuk ke hasil.

Recall 62,5% berarti sistem menemukan 5 dari 8 dokumen relevan. Tiga dokumen terlewat (#5, #26, #32).

F1 55,6% menunjukkan performa yang perlu ditingkatkan.

Penyebab Perbedaan Performa

- Kata "vaksin" memiliki IDF rendah (0,3565) karena muncul di 22 dari 50 dokumen (44%). Kata ini kurang diskriminatif - banyak dokumen mengandung "vaksin" tanpa membahas balita.
- Kata "balita" juga cukup umum (IDF 0,3768, $df=21$). Kombinasi dua kata dengan IDF rendah menghasilkan retrieval yang kurang tajam.
- Dibandingkan kueri 1 di mana "campak" memiliki IDF tinggi, kueri 2 tidak memiliki term yang cukup diskriminatif.

Kualitas Sistem Secara Keseluruhan

Sistem Mini Search Engine yang dibangun menunjukkan performa yang memadai dengan rata-rata F1-Measure sebesar 0,707 (70,7%). Sistem bekerja sangat baik untuk kueri dengan term yang spesifik/jarang (IDF tinggi), namun

performa menurun untuk kueri dengan term umum (IDF rendah). Ini adalah karakteristik yang diharapkan dari model TF-IDF + VSM, karena kemampuan diskriminasi term sangat bergantung pada nilai IDF.